

Gestión de Proyectos de Inteligencia Artificial

Actividad 8: Documento técnico



Gibran Martínez Figueroa

19/07/2026

Actividad 8: Documento técnico

Objetivo: Implementar la monitorización, mantenimiento y gobernanza operativa, asegurando la continuidad y confiabilidad del servicio. Al finalizar, deberás proporcionar evidencia documentada de cada fase del proceso, incluyendo el uso adecuado de herramientas y la simulación de incidentes críticos.

Introducción

Los modelos de machine learning al estar desplegados en entornos de producción presentan ciertos criterios que deben ser monitoreados constantemente para garantizar su funcionamiento correcto. Tener un modelo correctamente monitoreado nos garantiza su disponibilidad y confiabilidad mientras se está ejecutando.

Para el desarrollo de esta actividad se utilizará un modelo de clasificación de aprobación de créditos implementado mediante Random Forest, simulando un escenario empresarial donde una institución financiera evalúa solicitudes de clientes en tiempo real. Este caso de uso fue seleccionado debido a que representa una aplicación común de Machine Learning en producción y permite evaluar tanto métricas de negocio como indicadores técnicos asociados a la operación del servicio.

Como herramienta principal de monitoreo se utilizará MLflow, una plataforma ampliamente utilizada para la gestión del ciclo de vida de modelos de Machine Learning. MLflow permite registrar métricas, parámetros, versiones de modelos y resultados de experimentación, facilitando el seguimiento del rendimiento del modelo durante su operación. Adicionalmente, la herramienta proporciona capacidades para comparar versiones, analizar tendencias de desempeño y generar evidencia de monitoreo que puede integrarse con dashboards y sistemas de alertamiento.

Para simular un ambiente de producción, se definen las métricas operativas, registros, tasas de ejecución y SLO. a partir de estos parámetros se diseñarán las alertas y medidas preventivas que nos permitan detectar anomalías o errores durante el despliegue del modelo, así mismo esta estrategia puede ayudarnos a minimizar el ruido y priorizar incidentes según el impacto. También se pueden tomar medidas de acción de respuesta automatizada para distintos escenarios.

Por último se realizan simulaciones controladas de incidentes, con la finalidad de valorar si los procedimientos de respuesta son efectivos según las acciones correctivas propuestas. Esto permitirá demostrar la aplicación de prácticas modernas de observabilidad y gobernanza operativa en sistemas basados en inteligencia artificial, garantizando la continuidad y calidad del servicio ofrecido.

Documento técnico:

1. Definición de Indicadores (Métricas, Logs y Trazas)

1.1 Estrategia de observabilidad del modelo

La estrategia de observabilidad propuesta tiene como objetivo supervisar continuamente el desempeño del modelo de aprobación de créditos en producción, permitiendo identificar oportunamente problemas relacionados con la calidad de las predicciones, el desempeño operacional del servicio y posibles cambios en el comportamiento de los datos de entrada.

La observabilidad se fundamenta en tres componentes principales: métricas, logs y trazas. Cada uno de estos elementos permite obtener visibilidad sobre distintos aspectos de la operación del modelo y facilita la toma de decisiones para garantizar la continuidad y confiabilidad del servicio.

1.2 Métricas de monitoreo del modelo

Las métricas permiten evaluar el estado de salud del modelo y del servicio de inferencia, proporcionando indicadores cuantitativos que pueden ser monitoreados en tiempo real mediante dashboards y sistemas de alertamiento.

Métricas de desempeño del modelo

Métrica	Descripción	Objetivo Operativo	Valor Objetivo
Accuracy	Porcentaje total de predicciones correctas	Mantener la calidad de las decisiones crediticias	> 90%
Precision	Porcentaje de aprobaciones correctamente clasificadas	Reducir aprobaciones erróneas	> 88%
Recall	Capacidad de identificar solicitudes válidas	Minimizar rechazos incorrectos	> 85%
F1-Score	Balance entre Precision y Recall	Garantizar estabilidad del modelo	> 86%
Error Rate	Porcentaje de predicciones incorrectas	Detectar degradación temprana	< 10%

Métricas operativas del servicio

Métrica	Descripción	Objetivo Operativo	Valor Objetivo
Latencia Promedio	Tiempo promedio de respuesta por solicitud	Garantizar una respuesta rápida al usuario	< 500 ms
Latencia P95	Tiempo máximo experimentado por el 95% de las solicitudes	Detectar degradaciones de rendimiento	< 800 ms
Throughput	Cantidad de solicitudes procesadas por minuto	Validar capacidad operativa	> 1000 solicitudes/minuto
Disponibilidad	Porcentaje de tiempo que el servicio permanece activo	Garantizar continuidad del servicio	99.9%
Uso de CPU	Consumo de procesamiento del servidor	Evitar saturación de recursos	< 80%
Uso de Memoria	Consumo de memoria RAM	Garantizar estabilidad del sistema	< 85%

Estas métricas van a ser agregadas para que mediante MLFlow se pueda evaluar el rendimiento del modelo y su estabilidad ya desplegado en un entorno de producción simulado

1.3 Registro de Logs

Este tipo de registros son de mucha importancia ya que representan un evento ocurrido detallado mientras el modelo se ejecuta, es decir, es una especie de bitácora de los resultados de cada corrida del modelo. Tener entendimiento de los logs nos permite realizar auditorías, diagnósticos y análisis de incidentes.

Para cada solicitud se espera recibir la siguiente información:

Campo Registrado	Descripción
Timestamp	Fecha y hora de ejecución
Request ID	Identificador único de la solicitud
Usuario	Identificador del cliente o solicitud
Variables de entrada	Datos enviados para evaluación
Predicción generada	Resultado emitido por el modelo
Probabilidad	Nivel de confianza de la predicción
Tiempo de respuesta	Duración del procesamiento
Estado	Éxito o error
Mensaje de error	Información detallada cuando exista una falla

Ejemplo de resultado esperado:

1. Fecha: 15/11/2025 10:32:21
2. Request_ID: CRD-10254
3. Resultado: APROBADO
4. Probabilidad: 93%
5. Latencia: 321 ms
6. Estado: SUCCESS

Esta información nos permitirá identificar errores recurrentes, poder aplicar análisis a las partes afectadas y validar históricamente el comportamiento del sistema, ya que cuenta con fechas de registro de ejecución podemos saber si hay una tendencia de fallos por épocas o por carga diferente de datos, supongamos que los fines de semana hay más solicitudes de crédito, y el sistema falla, podemos denominar si esta tendencia es por una sobrecarga de datos.

1.4 Registro de Trazas

Las trazas permiten monitorear el recorrido completo de una solicitud a través de los distintos componentes involucrados en el servicio.

La traza de una solicitud incluirá las siguientes etapas:

1. Recepción de la solicitud en el API.
2. Validación de datos de entrada.
3. Carga del modelo de inferencia.
4. Ejecución de la predicción.
5. Consulta de información complementaria en base de datos.
6. Construcción de respuesta.
7. Envío de resultado al usuario.

Y para cada taza se va a registrar lo siguiente:

Campo	Descripción
Trace ID	Identificador único de la transacción
Nombre del componente	Servicio ejecutado
Tiempo de ejecución	Duración de la etapa
Estado de ejecución	Correcto o fallido
Dependencias utilizadas	APIs o bases de datos involucrada

Analizar las trazas nos facilita la identificación de cuellos de botella y además podemos conocer rápidamente los componentes responsables de los aumentos de latencia en fallas.

1.5 Relación entre indicadores y objetivos operativos

cada indicador monitoreado se encuentra asociado a un resultado operativo específico.

Indicador	Objetivo Operativo
Accuracy	Mantener la calidad de las decisiones crediticias
Precision	Reducir riesgos financieros derivados de aprobaciones incorrectas
Recall	Evitar la pérdida de clientes potenciales
Latencia P95	Garantizar tiempos de respuesta aceptables
Disponibilidad	Mantener la continuidad del servicio

Throughput	Soportar la demanda operativa esperada
Logs de errores	Reducir el tiempo de diagnóstico de incidentes
Trazas distribuidas	Identificar rápidamente cuellos de botella del sistema

2. Diseño de Alertas Inteligentes

Las alertas inteligentes nos ayudan a que el modelo siempre esté disponible y que funcione correctamente, ya que el equipo de desarrollo puede saber la calidad de respuestas y disponibilidad a través de los Objetivos de Nivel de Servicio (SLO) definidos.

Para garantizar que el equipo designado al mantenimiento del sistema tenga la información necesaria se definen los siguientes SLO

SLO definidos

- Disponibilidad del servicio: 99.9%
- Latencia promedio menor a 500 ms.
- Accuracy superior al 90%.

Alertas configuradas

Alerta	Condición	Prioridad
Degradación del modelo	Accuracy < 85%	Alta
Latencia elevada	Latencia > 800 ms	Media
Uso excesivo de CPU	CPU > 80%	Media
Data Drift	PSI > 0.25	Alta

Error Budget o presupuesto de errores.

Se establece un error budget del 0.1% mensual, equivalente aproximadamente a 43 minutos de indisponibilidad al mes. Cuando este límite se aproxima, se priorizan actividades de estabilización antes de realizar nuevos cambios al sistema.

3. Descripción de Dashboards

Los dashboards permiten monitorear en tiempo real el estado del modelo y del servicio. Se puede decir que un dashboard es algo similar a un tablero de auto, en donde se muestra el estado actual del vehículo, es decir, nivel de gasolina, kilometraje, etc. de igual manera en un modelo que se encuentra operativo necesitamos ver nuestro tablero, y podemos visualmente saber el estado del modelo con simple información.

Dashboard Operativo

Nos muestra:

- Disponibilidad del servicio.
- Latencia promedio.
- Uso de CPU y memoria.
- Solicitudes procesadas por minuto.

Dashboard de Rendimiento del Modelo

Muestra:

- Accuracy.
- Precision.
- Recall.
- F1-Score.
- Tasa de error.

Dashboard de Data Drift

Muestra:

- Distribución de variables de entrada.
- Índice PSI.
- Comparación entre datos de entrenamiento y producción.

Esta información facilita la detección temprana de problemas y la toma de decisiones operativas.

4. Runbooks de Respuesta a Incidentes

Los runbooks establecen procedimientos estandarizados para responder rápidamente ante incidentes.

Incidente 1: Incremento de Latencia

Detecta cuando la latencia es superior a 800 ms durante 10 minutos. Y basado en esa información puede tomar acciones correctivas por ejemplo:

- Revisar uso de CPU y memoria.
- Validar conexiones a la base de datos.
- Escalar recursos del servicio.
- Monitorear la recuperación.

Y después de esos chequeos el resultado esperado es poder restablecer la latencia por debajo de 500 ms.

Incidente 2: Degradación del Modelo

Detecta cuando el índice de Accuracy es inferior al 85%. Y se pueden tomar las siguientes acciones:

- Analizar métricas del modelo.
- Revisar evidencia de data drift.
- Ejecutar rollback a una versión estable.
- Programar reentrenamiento.

Después de hacer esto se espera que el accuracy crezca superior al 90%

5. Estrategias de Detección de Data Drift

Identificar por que el modelo tiene data drift nos puede ayudar a saber que cambios significativos hubo en los datos utilizados para entrenar al modelo y los datos reales que recibimos en producción, es decir, si cambiamos la fuente de datos y hay un cambio podemos detectar si el valor de estabilidad rompe los parámetros establecidos:

Se utilizará el indicador Population Stability Index (PSI)

Valor PSI	Interpretación
Menor a 0.1	Sin cambios relevantes
Entre 0.1 y 0.25	Cambio moderado
Mayor a 0.25	Data drift significativo

6. Documentación de Respuesta Automatizada

Con el objetivo de reducir tiempos de recuperación, se definieron acciones automáticas ante incidentes frecuentes.

Evento Detectado	Respuesta Automática
Accuracy < 85%	Rollback del modelo
PSI > 0.25	Inicio de proceso de reentrenamiento
CPU > 80%	Escalamiento automático de recursos
Latencia > 800 ms	Generación de alerta y escalamiento

Estas acciones permiten restaurar el servicio de forma rápida, minimizando el impacto sobre los usuarios y garantizando la continuidad operativa.